

✓ Exploration de données : Projet Sell4All

Ce notebook a pour but d'analyser et de nettoyer les données des clients de l'entreprise Sell4All. L'objectif final est de préparer ces données pour un futur modèle d'intelligence artificielle.

Commencez à coder ou à [générer](#) avec l'IA.

```
import pandas as pd
import matplotlib.pyplot as plt
```

✓ 1. Lecture des données

Nous commençons par lire le fichier CSV contenant les informations des utilisateurs.

```
df = pd.read_csv('dataset-sell4all.csv')
df.head()
```

	Name	Phone Number	Email	Address	Country	Postal code	L
0	Aaron Cote	966-7625	elit@hotmail.org	699-5837 Risus Street	Norway	4126	co
1	Angelica Lawson	232-3051	diam.proin@google.org	481-8428 Magna. Street	Pakistan	518885	
2	Louis Gilbert	1-997-733-0134	lorem.fringilla@hotmail.org	Ap #192-2082 Enim. Ave	Colombia	575444	
3	Basia Finley	1-987-322-7148	tristique.aliquet@icloud.co	608-2732 Nec Rd.	South Africa	5973-5765	
4	Rhona Sears	387-7682	iaculis.odio.nam@protonmail.org	8763 In Rd.	France	37476	:

Étapes suivantes :

[Générer du code avec df](#)

[New interactive sheet](#)

✓ 2. Résumé technique des données

Nous affichons un résumé technique de notre jeu de données pour comprendre sa structure.

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 505 entries, 0 to 504
Data columns (total 11 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Name                                505 non-null    object
1   Phone Number                        505 non-null    object
2   Email                              505 non-null    object
3   Address                            505 non-null    object
4   Country                            505 non-null    object
5   Postal code                         505 non-null    object
6   Last date of connection             505 non-null    object
7   Last time of connection             505 non-null    object
8   Age                                 505 non-null    int64
9   Gender                             505 non-null    object
10  Customer spendings                  505 non-null    int64
dtypes: int64(2), object(9)
memory usage: 43.5+ KB
```

Explication du résumé technique :

- **Combien y a-t-il d'entrées dans l'ensemble de données ?** L'ensemble de données contient 505 entrées (lignes) numérotées de l'index 0 à 504.
- **Qu'est-ce que « non nul » ?** Le terme « non nul » (ou non-null) indique le nombre de valeurs qui existent réellement et qui ne sont pas vides dans une colonne. Par exemple, si une colonne possède 505 valeurs non nulles, cela signifie qu'il n'y a aucune donnée manquante pour cette variable.
- **Quels types de données sont présents dans l'ensemble de données ?** Les types de données présents sont principalement :
 - `int64` : représente les nombres entiers (utilisé par exemple pour l'âge et les dépenses des clients).
 - `object` : représente du texte ou des chaînes de caractères (utilisé par exemple pour le nom, le pays, le genre, etc.).

✓ 3. Analyse statistique basique

Calcul de la moyenne et de la médiane pour les colonnes Age et Customer spendings.

```
# Calcul de la moyenne et de la médiane pour l'Age
mean_age = df['Age'].mean()
median_age = df['Age'].median()

# Calcul de la moyenne et de la médiane pour les dépenses (Customer spending)
mean_spending = df['Customer spendings'].mean()
median_spending = df['Customer spendings'].median()

print(f"Moyenne d'âge : {mean_age:.2f} ans")
print(f"Médiane d'âge : {median_age} ans")
print(f"Moyenne des dépenses : {mean_spending:.2f} €")
print(f"Médiane des dépenses : {median_spending} €")
```

```
Moyenne d'âge : 46.08 ans
Médiane d'âge : 46.0 ans
Moyenne des dépenses : 311.17 €
Médiane des dépenses : 307.0 €
```

✓ Bonus : Calcul de la médiane d'âge pour chaque pays

```
median_age_by_country = df.groupby('Country')['Age'].median()
print(median_age_by_country)
```

Country	
Australia	44.0
Austria	43.0
Belgium	39.0
Brazil	49.5
Canada	46.0
Chile	46.0
China	35.0
Colombia	29.0
Costa Rica	48.0
France	56.5
Germany	53.0
India	45.5
Indonesia	41.5
Ireland	49.0
Italy	41.0
Mexico	47.0
Netherlands	48.0
New Zealand	38.0
Nigeria	37.0
Norway	54.0
Pakistan	44.0
Peru	38.0
Philippines	51.0
Poland	49.5
Russian Federation	48.0
Singapore	41.5
South Africa	43.0
South Korea	49.5
Spain	54.5
Sweden	40.0
Turkey	60.0
Ukraine	46.0

United Kingdom	48.5
United States	48.5
Vietnam	48.0

Name: Age, dtype: float64


✓ 4. Visualisation des données

Graphique à barres illustrant les dépenses totales par pays.

```
# Regrouper les dépenses par pays et faire la somme, puis trier par ordre de
spendings_by_country = df.groupby('Country')['Customer spendings'].sum().sort()

# Création du graphique
plt.figure(figsize=(14, 6))
spendings_by_country.plot(kind='bar', color='#4C72B0', edgecolor='black')

plt.title('Dépenses totales des clients par pays', fontsize=14, fontweight='bold')
plt.xlabel('Pays', fontsize=12)
plt.ylabel('Dépenses totales (€)', fontsize=12)
plt.xticks(rotation=45, ha='right')
plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.tight_layout()
plt.show()
```



✓ 5. Nettoyage des données

Préparation du dataset pour le modèle en supprimant les doublons et les utilisateurs ayant dépensé moins de 10 €.

```
# Suppression des lignes avec moins de 10 € de dépenses
df_cleaned = df[df['Customer spendings'] >= 10]

# Suppression des lignes dupliquées
df_cleaned = df_cleaned.drop_duplicates()

# Conservation uniquement des colonnes requises : Country, Age, Gender, Cust
```

```
columns_to_keep = ['Country', 'Age', 'Gender', 'Customer spendings']
df_cleaned = df_cleaned[columns_to_keep]

# Affichage d'un aperçu des données nettoyées
df_cleaned.head()
```

	Country	Age	Gender	Customer spendings
0	Norway	71	Man	356
1	Pakistan	37	Women	173
2	Colombia	24	Women	105
3	South Africa	37	Women	28
4	France	42	Women	13



Étapes suivantes :

[Générer du code avec df_cleaned](#)

[New interactive sheet](#)

✓ 6. Exportation du fichier nettoyé

Sauvegarde des données propres dans un nouveau fichier CSV.

```
df_cleaned.to_csv('cleaned_dataset-sell4all.csv', index=False)
print("Les données nettoyées ont été sauvegardées avec succès.")
```

Les données nettoyées ont été sauvegardées avec succès.